Рубежный контроль №2

Киреев Андрей Сергеевич ИУ5-63Б

Вариант 12

Задача:

Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Методы для ИУ5-63Б.

Метод №1: "Дерево решений". Метод №2: "Случайный лес".

Импорт библиотек:

In [284…

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

Загрузка и обработка пропусков в данных:

In [285…

```
# загрузка набора данных
data = pd.read_csv('data.csv', sep=",")
# размер набора данных
data.shape
```

Out[285… (18207, 89)

In [286…

```
# первые 5 строк набора данных
data.head()
```

Out[286…

	Unnamed: 0	ID	Name	Age	Photo	Nationality
0	0	158023	L. Messi	31	https://cdn.sofifa.org/players/4/19/158023.png	Argentina
1	1	20801	Cristiano Ronaldo	33	https://cdn.sofifa.org/players/4/19/20801.png	Portuga
2	2	190871	Neymar Jr	26	https://cdn.sofifa.org/players/4/19/190871.png	Brazi
3	3	193080	De Gea	27	https://cdn.sofifa.org/players/4/19/193080.png	Spair
4	4	192985	K. De Bruyne	27	https://cdn.sofifa.org/players/4/19/192985.png	Belgiur

5 rows × 89 columns

In [287…

```
parts = np.split(data, [28], axis=1)
data = parts[0]
parts = np.split(data, [500], axis=0)
data = parts[0]
```

In [288…

```
# список колонок с типами данных
data.dtypes
```

Out[288…

```
Unnamed: 0                object
ID                        object
Name                      object
Age                       object
Photo                     object
Nationality               object
Flag                      object
Overall                   object
Potential                 object
Club                      object
Club Logo                 object
Value                     object
Wage                      object
Special                   object
Preferred Foot            object
International Reputation  object
Weak Foot                 object
Skill Moves               object
Work Rate                 object
Body Type                 object
Real Face                 object
Position                  object
Jersey Number             object
Joined                    object
Loaned From               object
Contract Valid Until      object
Height                    object
Weight                    object
dtype: object
```

In [289…
```
data = data.drop('Unnamed: 0', axis = 1)
data = data.drop('Name', axis = 1)
data = data.drop('Photo', axis = 1)
data = data.drop('Flag', axis = 1)
data = data.drop('Club Logo', axis = 1)
data = data.drop('Loaned From', axis = 1)
data = data.drop('Work Rate', axis = 1)
data = data.drop('Nationality', axis = 1)
data = data.drop('Club', axis = 1)
data = data.drop('Body Type', axis = 1)
data = data.drop('Real Face', axis = 1)
data = data.drop('Position', axis = 1)
data = data.drop('Joined', axis = 1)
data = data.drop('Contract Valid Until', axis = 1)
```

In [290…
```
data.dtypes
```

Out[290…
```
ID                          object
Age                         object
Overall                     object
Potential                   object
Value                       object
Wage                        object
Special                     object
Preferred Foot              object
International Reputation    object
Weak Foot                   object
Skill Moves                 object
Jersey Number               object
Height                      object
Weight                      object
dtype: object
```

In [291…
```
dct = {'Left': 0, 'Right': 1}
data['Preferred_Foot']=data['Preferred Foot'].map(dct)
data
data = data.drop('Preferred Foot', axis = 1)
```

In [292…
```
# Удаление строк, содержащих пустые значения
data_new = data.dropna(axis=0, how='any')
(data.shape, data_new.shape)
```

Out[292…
```
((500, 14), (500, 14))
```

In [293…
```
# проверим, есть ли пропущенные значения
data_new.isnull().sum()
```

Out[293…
```
ID                          0
Age                         0
Overall                     0
Potential                   0
Value                       0
Wage                        0
Special                     0
International Reputation    0
Weak Foot                   0
Skill Moves                 0
Jersey Number               0
Height                      0
Weight                      0
Preferred_Foot              0
dtype: int64
```

In [294…
```
data=data_new
data.head()
```

Out[294…

	ID	Age	Overall	Potential	Value	Wage	Special	International Reputation	Weak Foot	Skill Moves
0	158023	31	94	94	€110.5M	€565K	2202	5.0	4.0	4.0
1	20801	33	94	94	€77M	€405K	2228	5.0	4.0	5.0
2	190871	26	92	93	€118.5M	€290K	2143	5.0	5.0	5.0
3	193080	27	91	93	€72M	€260K	1471	4.0	3.0	1.0
4	192985	27	91	92	€102M	€355K	2281	4.0	5.0	4.0

In [295…
```
data.shape
```

Out[295…
```
(500, 14)
```

Масштабирование данных:

MinMax масштабирование

In [296…
```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

In [297…
```
# Числовые колонки для масштабирования
colums = ['ID','Age','Overall','Potential','Special','International Reputat
scale = colums
```

In [298…
```
sc = MinMaxScaler()
scd = sc.fit_transform(data[scale])
```

In [299…

```
# Добавим масштабированные данные в набор данных
for i in range(len(scale)):
    col = scale[i]
    new_name = col + '_scaled'
    data[new_name] = scd[:,i]
```

In [300…

```
data.head()
```

Out[300…

	ID	Age	Overall	Potential	Value	Wage	Special	International Reputation	Weak Foot	Skill Moves
0	158023	31	94	94	€110.5M	€565K	2202	5.0	4.0	4.0
1	20801	33	94	94	€77M	€405K	2228	5.0	4.0	5.0
2	190871	26	92	93	€118.5M	€290K	2143	5.0	5.0	5.0
3	193080	27	91	93	€72M	€260K	1471	4.0	3.0	1.0
4	192985	27	91	92	€102M	€355K	2281	4.0	5.0	4.0

5 rows × 23 columns

In [301…

```
for col in scale:
    colsc = col + '_scaled'

    fig, ax = plt.subplots(1, 2, figsize=(8,3))
    ax[0].hist(data[col], 50)
    ax[1].hist(data[colsc], 50)
    ax[0].title.set_text(col)
    ax[1].title.set_text(colsc)
    plt.show()
```

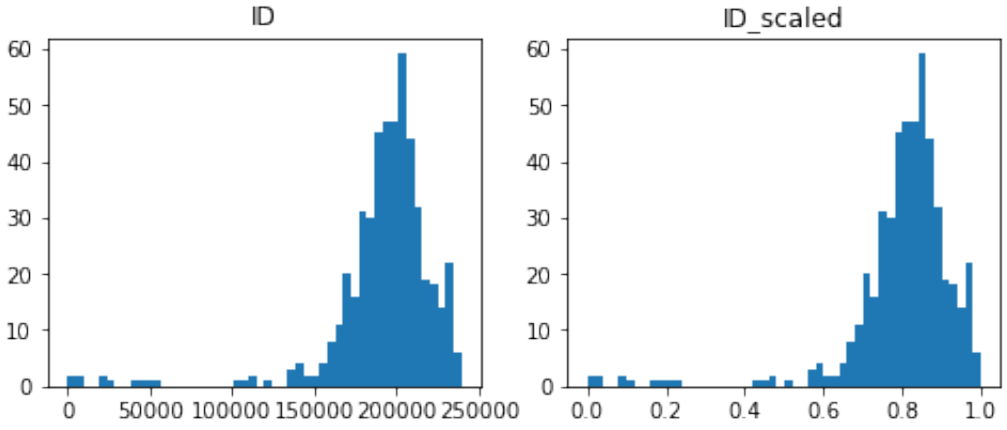

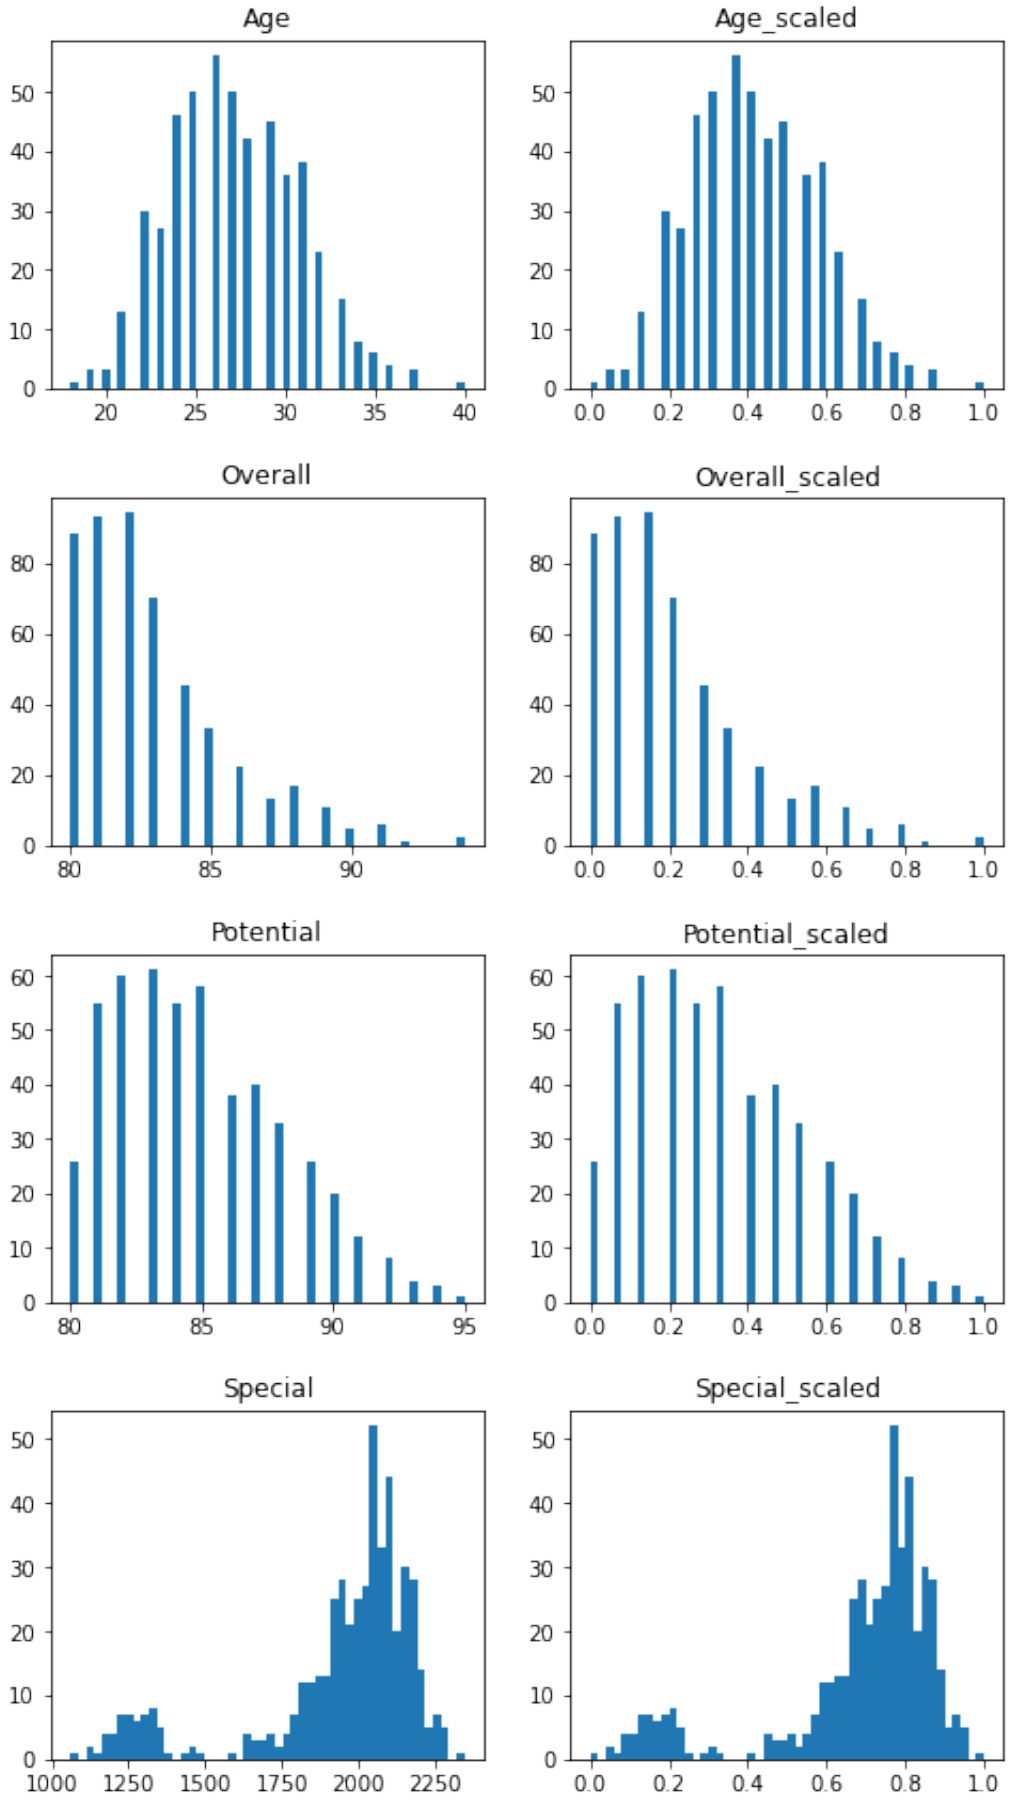
Age
Age_scaled
Overall
Overall_scaled
Potential
Potential_scaled
Special
Special_scaled

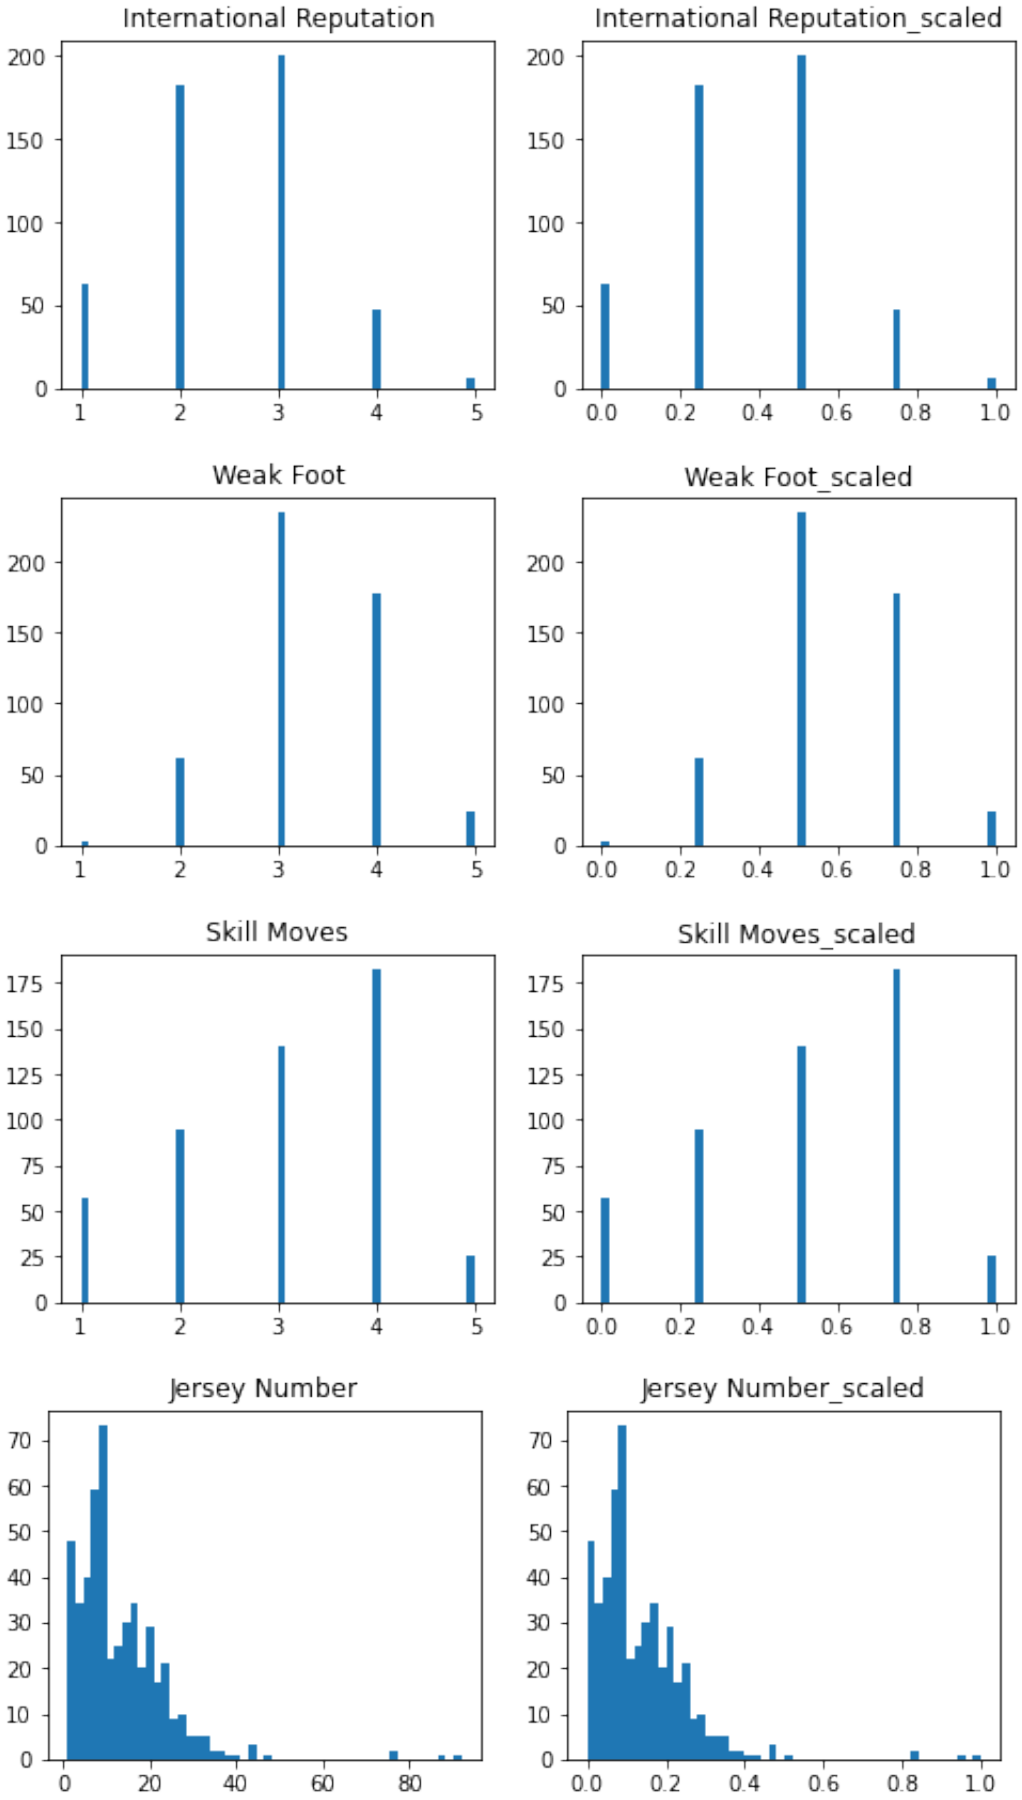

In [302…

```
data.drop(colums, axis = 1, inplace = True)
```

In [303…

```
data = data.drop('Height', axis = 1)
data['Value'] = data.Value.str.replace('€','')
data['Wage'] = data.Wage.str.replace('€','')
data['Value'] = data.Value.str.replace('M','')
data['Wage'] = data.Wage.str.replace('K','')
data['Weight'] = data.Weight.str.replace('lbs','')
```

In [304…

```
data.head()
```

Out[304…

	Value	Wage	Weight	Preferred_Foot	ID_scaled	Age_scaled	Overall_scaled	Potential_sc
0	110.5	565	159	0	0.660554	0.590909	1.000000	0.93
1	77	405	183	1	0.086802	0.681818	1.000000	0.93
2	118.5	290	150	1	0.797898	0.363636	0.857143	0.86
3	72	260	168	1	0.807134	0.409091	0.785714	0.86
4	102	355	154	1	0.806737	0.409091	0.785714	0.80

Построение моделей

In [305…

```
X = data.drop(['ID_scaled'], axis = 1)
Y = data.ID_scaled
print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', Y.head(
```

Входные данные:

```
    Value Wage Weight  Preferred_Foot  Age_scaled  Overall_scaled  \
0   110.5  565    159               0    0.590909        1.000000
1      77  405    183               1    0.681818        1.000000
2   118.5  290    150               1    0.363636        0.857143
3      72  260    168               1    0.409091        0.785714
4     102  355    154               1    0.409091        0.785714

   Potential_scaled  Special_scaled  International Reputation_scaled  \
0          0.933333        0.888025                             1.00
1          0.933333        0.908243                             1.00
2          0.866667        0.842146                             1.00
3          0.866667        0.319596                             0.75
4          0.800000        0.949456                             0.75

   Weak Foot_scaled  Skill Moves_scaled  Jersey Number_scaled
0              0.75                0.75              0.098901
1              0.75                1.00              0.065934
2              1.00                1.00              0.098901
3              0.50                0.00              0.000000
4              1.00                0.75              0.065934
```

Выходные данные:

```
 0    0.660554
1    0.086802
2    0.797898
3    0.807134
4    0.806737
Name: ID_scaled, dtype: float64
```

In [306…

```
X_train,  X_test,  Y_train,  Y_test = train_test_split(X,  Y, random_state
print('Входные параметры обучающей выборки:\n\n',X_train.head(), \
      '\n\nВходные параметры тестовой выборки:\n\n', X_test.head(), \
      '\n\nВыходные параметры обучающей выборки:\n\n', Y_train.head(), \
      '\n\nВыходные параметры тестовой выборки:\n\n', Y_test.head())
```

Входные параметры обучающей выборки:

```
     Value Wage Weight  Preferred_Foot  Age_scaled  Overall_scaled  \
141     24   42    192               1    0.500000        0.285714
383     16   59    183               1    0.454545        0.071429
135   24.5  165    154               1    0.454545        0.285714
493   11.5   63    196               1    0.500000        0.000000
122     39   72    154               0    0.318182        0.285714

     Potential_scaled  Special_scaled  International Reputation_scaled  \
141          0.333333        0.212286                             0.25
383          0.133333        0.595645                             0.50
135          0.266667        0.867030                             0.50
493          0.000000        0.632193                             0.25
122          0.466667        0.801711                             0.25

     Weak Foot_scaled  Skill Moves_scaled  Jersey Number_scaled
141              0.50                0.00              0.000000
383              0.75                0.25              0.384615
135              0.25                0.25              0.010989
493              0.50                0.25              0.021978
122              0.50                0.75              0.208791
```

```
Входные параметры тестовой выборки:

     Value Wage Weight  Preferred_Foot  Age_scaled  Overall_scaled  \
90      37   66    163               1    0.500000        0.357143
254   26.5  140    137               1    0.318182        0.142857
283     21  140    143               1    0.545455        0.142857
445     15   20    143               0    0.318182        0.000000
461   14.5   24    157               1    0.545455        0.000000

     Potential_scaled  Special_scaled  International Reputation_scaled  \
90           0.333333        0.823484                              0.25
254          0.200000        0.804821                              0.25
283          0.133333        0.706065                              0.50
445          0.133333        0.750389                              0.25
461          0.000000        0.735614                              0.00

     Weak Foot_scaled  Skill Moves_scaled  Jersey Number_scaled
90               0.75                0.50              0.098901
254              0.50                0.75              0.065934
283              1.00                0.75              0.109890
445              0.25                0.50              0.021978
461              0.75                0.75              0.065934

Выходные параметры обучающей выборки:

 141    0.747217
383    0.774349
135    0.787470
493    0.801310
122    0.856848
Name: ID_scaled, dtype: float64

Выходные параметры тестовой выборки:

 90     0.792220
254    0.867402
283    0.792186
445    0.883131
461    0.854461
Name: ID_scaled, dtype: float64
```

"Дерево решений"

In [307…

```
from sklearn.tree import DecisionTreeRegressor
```

In [308…

```
dtc = DecisionTreeRegressor(random_state=1).fit(X_train, Y_train)
data_test_predicted_dtc = dtc.predict(X_test)
```

"Случайный лес"

In [309…
```
from sklearn.ensemble import RandomForestRegressor

from sklearn.metrics import mean_squared_error, r2_score
```

In [310…
```
rf = RandomForestRegressor(random_state=1).fit(X_train, Y_train)
data_test_predicted_rf = rf.predict(X_test)
```

Оценка качества моделей

In [311…
```
print('Метрика MSE:\nДерево решений: {}\nСлучайный лес: {}'.format(mean_sq
```

```
Метрика MSE:
Дерево решений: 0.017932644991507766
Случайный лес: 0.012360212855212596
```

In [312…
```
print('Метрика R\u00B2:\nДерево решений: {}\nСлучайный лес: {}'.format(r2_
```

```
Метрика R²:
Дерево решений: 0.4629685124546095 7
Случайный лес: 0.6298469356218279
```

Вывод

Исходя из оценки качества построенных моделей можно увидеть, что модели "Случайный лес" и "Дерево решений" одинаково справились с поставленной задачей